

Hitungan Manual: BoW, TF-IDF, dan Cosine Similarity

1. Dataset Mainan

Tiga dokumen pendek (lowercase, tanpa penghapusan stopwords agar mudah dihitung):

- d_1 : “barang cepat sampai”
- d_2 : “pengiriman cepat dan rapi”
- d_3 : “sangat lambat pengiriman”

Kosakata global (urut abjad) kita tetapkan sebagai

$$\mathcal{V} = [\text{barang, cepat, sampai, pengiriman, dan, rapi, sangat, lambat}],$$

dengan ukuran korpus $N = 3$ dokumen.

2. Bag-of-Words (BoW)

2.1 Definisi

Representasi BoW untuk sebuah dokumen d adalah vektor frekuensi:

$$\text{BoW}(d) = [f(w_1, d), f(w_2, d), \dots, f(w_V, d)],$$

dengan $f(w_i, d)$ menyatakan jumlah kemunculan kata w_i dalam d , dan $V = |\mathcal{V}|$.

2.2 Perhitungan BoW

Panjang dokumen:

$$|d_1| = 3, \quad |d_2| = 4, \quad |d_3| = 3.$$

Susunan vektor mengikuti urutan \mathcal{V} .

$$\text{BoW}(d_1) = [1, 1, 1, 0, 0, 0, 0, 0]$$

$$\text{BoW}(d_2) = [0, 1, 0, 1, 1, 1, 0, 0]$$

$$\text{BoW}(d_3) = [0, 0, 0, 1, 0, 0, 1, 1]$$

3. TF, DF, dan IDF

3.1 Term Frequency (TF)

Gunakan TF ternormalisasi (proporsional terhadap panjang dokumen):

$$\text{tf}(t, d) = \frac{f_{t,d}}{|d|}.$$

Contoh:

- Di d_1 : setiap kata yang muncul memiliki $\text{tf} = \frac{1}{3}$.
- Di d_2 : setiap kata yang muncul memiliki $\text{tf} = \frac{1}{4}$.
- Di d_3 : setiap kata yang muncul memiliki $\text{tf} = \frac{1}{3}$.

3.2 Document Frequency (DF)

$df(t)$ adalah jumlah dokumen yang *mengandung* kata t :

$$\begin{aligned}df(\text{barang}) &= 1 \ (d_1), & df(\text{cepat}) &= 2 \ (d_1, d_2), & df(\text{sampai}) &= 1 \ (d_1), \\df(\text{pengiriman}) &= 2 \ (d_2, d_3), & df(\text{dan}) &= 1 \ (d_2), & df(\text{rapi}) &= 1 \ (d_2), \\df(\text{sangat}) &= 1 \ (d_3), & df(\text{lambat}) &= 1 \ (d_3).\end{aligned}$$

3.3 Inverse Document Frequency (IDF)

Pakai varian IDF yang stabil terhadap pembagi nol:

$$idf(t) = \ln\left(\frac{N}{1 + df(t)}\right), \quad N = 3.$$

Maka:

$$df(t) = 1 \Rightarrow idf(t) = \ln\left(\frac{3}{2}\right) \approx 0.4055, \quad df(t) = 2 \Rightarrow idf(t) = \ln\left(\frac{3}{3}\right) = 0.$$

Konsekuensinya:

$$\begin{aligned}idf(\text{barang}) &= idf(\text{sampai}) = idf(\text{dan}) = idf(\text{rapi}) = idf(\text{sangat}) = idf(\text{lambat}) \approx 0.4055, \\idf(\text{cepat}) &= idf(\text{pengiriman}) = 0.\end{aligned}$$

4. Vektor TF-IDF

Definisi dasar:

$$tfidf(t, d) = tf(t, d) \cdot idf(t).$$

Kita tampilkan hanya komponen yang tidak nol (pembulatan 4 desimal).

4.1 Dokumen d_1 (“barang cepat sampai”)

$$tfidf(\text{barang}, d_1) = \frac{1}{3} \cdot 0.4055 \approx 0.1352$$

$$tfidf(\text{cepat}, d_1) = \frac{1}{3} \cdot 0 = 0$$

$$tfidf(\text{sampai}, d_1) = \frac{1}{3} \cdot 0.4055 \approx 0.1352$$

Vektor TF-IDF (urutan \mathcal{V}):

$$[0.1352, 0, 0.1352, 0, 0, 0, 0, 0].$$

4.2 Dokumen d_2 (“pengiriman cepat dan rapi”)

$$tfidf(\text{pengiriman}, d_2) = \frac{1}{4} \cdot 0 = 0, \quad tfidf(\text{cepat}, d_2) = \frac{1}{4} \cdot 0 = 0,$$

$$tfidf(\text{dan}, d_2) = \frac{1}{4} \cdot 0.4055 \approx 0.1014, \quad tfidf(\text{rapi}, d_2) = \frac{1}{4} \cdot 0.4055 \approx 0.1014.$$

Vektor TF-IDF:

$$[0, 0, 0, 0, 0.1014, 0.1014, 0, 0].$$

4.3 Dokumen d_3 (“sangat lambat pengiriman”)

$$tfidf(\text{sangat}, d_3) = \frac{1}{3} \cdot 0.4055 \approx 0.1352, \quad tfidf(\text{lambat}, d_3) = \frac{1}{3} \cdot 0.4055 \approx 0.1352,$$

$$tfidf(\text{pengiriman}, d_3) = \frac{1}{3} \cdot 0 = 0.$$

Vektor TF-IDF:

$$[0, 0, 0, 0, 0, 0, 0.1352, 0.1352].$$

5. Cosine Similarity (Contoh)

Misalkan ada *query* q : “barang cepat”. Dengan kosakata yang sama,

$$|q| = 2, \quad \text{tf}(\text{barang}, q) = \frac{1}{2}, \quad \text{tf}(\text{cepat}, q) = \frac{1}{2}.$$

Dengan $\text{idf}(\text{barang}) \approx 0.4055$ dan $\text{idf}(\text{cepat}) = 0$:

$$\text{tfidf}(\text{barang}, q) = \frac{1}{2} \cdot 0.4055 \approx 0.2027, \quad \text{tfidf}(\text{cepat}, q) = \frac{1}{2} \cdot 0 = 0.$$

Vektor TF-IDF q (urutan \mathcal{V}):

$$\mathbf{q} = [0.2027, 0, 0, 0, 0, 0, 0, 0].$$

Cosine similarity antara \mathbf{q} dan \mathbf{d} didefinisikan:

$$\cos(\theta) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|}.$$

Dengan d_1 .

$$\mathbf{d}_1 = [0.1352, 0, 0.1352, 0, 0, 0, 0, 0].$$

$$\mathbf{q} \cdot \mathbf{d}_1 = 0.2027 \times 0.1352 + 0 \times 0.1352 = 0.0274.$$

$$\|\mathbf{q}\| = \sqrt{0.2027^2} \approx 0.2027, \quad \|\mathbf{d}_1\| = \sqrt{0.1352^2 + 0.1352^2} \approx \sqrt{2 \times 0.0183} \approx 0.1913.$$

$$\cos(\mathbf{q}, \mathbf{d}_1) \approx \frac{0.0274}{0.2027 \times 0.1913} \approx \frac{0.0274}{0.0388} \approx 0.706.$$

Dengan d_2 dan d_3 . Karena \mathbf{q} hanya memiliki komponen “barang” dan d_2, d_3 tidak memiliki “barang”,

$$\mathbf{q} \cdot \mathbf{d}_2 = 0, \quad \mathbf{q} \cdot \mathbf{d}_3 = 0 \Rightarrow \cos(\mathbf{q}, \mathbf{d}_2) = 0, \quad \cos(\mathbf{q}, \mathbf{d}_3) = 0.$$

Kesimpulan: q paling mirip ke d_1 (nilai cosine terbesar).

6. Catatan Singkat tentang N-gram

Jika menggunakan *bigram* untuk menangkap negasi:

$$\text{dokumen: “tidak bagus”} \Rightarrow \text{fitur bigram: “tidak_bagus”}.$$

BoW bigram:

$$\text{BoW}_{\text{bigram}}(d) = [f(\text{“tidak_bagus”, } d), \dots].$$

Skor TF-IDF bigram dihitung sama: gunakan frekuensi bigram sebagai $f_{t,d}$ lalu kalikan dengan $\text{idf}(t)$.

7. Ringkasan

- BoW menghitung *frekuensi kata* per dokumen.
- TF-IDF menurunkan bobot kata yang *terlalu umum* dan meninggikan kata *informatif*.
- Cosine similarity mengukur kedekatan vektor TF-IDF antar teks.
- Vektor TF-IDF siap dipakai sebagai fitur untuk model klasik (LogReg/SVM/NB).